

Modelo Adaline e Regra LMS

Prof. Dr. Guilherme de Alencar Barreto

Outubro/2007

Departamento de Engenharia de Teleinformática
Programa de Pós-Graduação em Engenharia de Teleinformática (PPGETI)
Universidade Federal do Ceará (UFC), Fortaleza-CE

gbarreto@ufc.br

1 Definições Preliminares

De início, vamos assumir que existe uma lei matemática $\mathbf{F}(\cdot)$, também chamada aqui de função ou mapeamento, que relaciona um vetor de entrada qualquer, $\mathbf{x} \in \mathbb{R}^{p+1}$, com um vetor de saída, $\mathbf{d} \in \mathbb{R}^q$. Esta relação, representada genericamente na Figura 1, pode ser descrita matematicamente da seguinte forma:

$$\mathbf{d} = \mathbf{F}[\mathbf{x}] \quad (1)$$

em que se assume que $\mathbf{F}(\cdot)$ é totalmente desconhecida, ou seja, não sabemos de antemão quais são as *fórmulas* usadas para associar um vetor de entrada $\mathbf{x}$ com seu vetor de saída $\mathbf{d}$ correspondente.




Figura 1: Representação simplificada de um mapeamento entrada-saída genérico.

O mapeamento $\mathbf{F}(\cdot)$ pode ser tão simples quanto um mapeamento linear, tal como

$$\mathbf{d} = \mathbf{M}\mathbf{x} \quad (2)$$

em que $\mathbf{M}$ é uma matriz de dimensão $(p + 1) \times q$. Contudo, $\mathbf{F}(\cdot)$ pode ser bastante complexo, envolvendo relações não-lineares entre as variáveis de entrada e saída. É justamente o funcionamento da relação matemática $\mathbf{F}(\cdot)$ que se deseja *imitar* através do uso de algoritmos adaptativos, tais como as redes neurais.

Supondo que a única fonte de informação que nós temos a respeito de $\mathbf{F}(\cdot)$ é conjunto finito de N pares entrada-saída observados (ou medidos), ou seja:

$$\begin{array}{cc} \mathbf{x}_1, & \mathbf{d}_1 \\ \mathbf{x}_2, & \mathbf{d}_2 \\ \vdots & \vdots \\ \mathbf{x}_N, & \mathbf{d}_N \end{array} \quad (3)$$

Os pares entrada-saída mostrados acima podem ser representados de maneira simplificada como $\{\mathbf{x}_\mu, \mathbf{d}_\mu\}$, em que μ é um apenas índice simbolizando o μ -ésimo par do conjunto de dados. Uma maneira de se adquirir conhecimento sobre $\mathbf{F}(\cdot)$ se dá exatamente através dos uso destes pares.

Para isto pode-se utilizar uma rede neural qualquer para implementar um mapeamento entrada-saída aproximado, representado como $\hat{\mathbf{F}}(\cdot)$, tal que:

$$\mathbf{y} = \hat{\mathbf{F}}[\mathbf{x}] \quad (4)$$

em que $\mathbf{y}$ é a saída gerada pela rede neural que, espera-se, seja muito próxima da saída real $\mathbf{d}$. Dá-se o nome de *Aprendizado Indutivo* ao processo de obtenção da relação matemática geral $\hat{\mathbf{F}}(\cdot)$ a partir de apenas alguns pares $\{\mathbf{x}_\mu, \mathbf{d}_\mu\}$ disponíveis.

A seguir será mostrado um dos primeiros modelos matemáticos adaptativos usados com o propósito de obter uma representação aproximada de um mapeamento entrada-saída qualquer.

2 Modelo ADALINE

Nesta seção descreveremos um tipo elementar de algoritmo adaptativo, chamado **Elemento Linear Adaptativo** (*ADaptive LINear Element* - ADALINE), composto de apenas um elemento processador (neurônio) linear, proposto por Widrow & Hoff [1, 2, 3, 4].

O modelo ADALINE têm seus parâmetros ajustados por meio de uma regra de atualização recursiva denominada **Regra de Widrow-Hoff**, também conhecido como Regra Delta, ou ainda, como algoritmo de adaptação LMS (*Least Mean Square*).

O modelo ADALINE é mostrado na Figura 2. O vetor de entrada é então definido como:

$$\mathbf{x}(t) = \begin{pmatrix} x_0(t) \\ x_1(t) \\ \vdots \\ x_p(t) \end{pmatrix} = \begin{pmatrix} -1 \\ x_1(t) \\ \vdots \\ x_p(t) \end{pmatrix} \quad (5)$$

em que $x_j(t)$ denota uma componente qualquer do vetor de entrada $\mathbf{x}(t)$ e t indica o instante de apresentação deste vetor ao modelo ADALINE.

Como estamos tratando apenas de um modelo com um único neurônio, então o vetor de saída reduz-se a um escalar, ou seja:

$$\mathbf{d}(t) = d(t), \quad (6)$$

que pode assumir qualquer valor real, em princípio. Contudo, em problemas de classificação de padrões, a saída desejada assume geralmente apenas dois valores, tal como $d \in \{-1, +1\}$.




Figura 2: Arquitetura do modelo ADALINE.

O vetor de pesos associado ao neurônio do modelo ADALINE é representado da seguinte forma:

$$\mathbf{w} = \begin{pmatrix} w_0 \\ w_1 \\ \vdots \\ w_p \end{pmatrix} = \begin{pmatrix} \theta \\ w_1 \\ \vdots \\ w_p \end{pmatrix} \quad (7)$$

em que θ define um limiar (*threshold* ou *bias*) associado ao neurônio.

O vetor de pesos $\mathbf{w}$ e o limiar θ correspondem aos parâmetros ajustáveis do modelo ADALINE. A seguir são descritos os passos que compõem o treinamento (ou ajuste) destes parâmetros.

Após a apresentação de um vetor de entrada $\mathbf{x}$, na iteração t , a ativação $u(t)$ do neurônio é calculada pela seguinte expressão:

$$\begin{aligned} u(t) &= \sum_{j=1}^p w_j(t)x_j(t) - \theta \\ &= \sum_{j=1}^p w_j(t)x_j(t) + w_0(t)x_0(t) \\ &= \sum_{j=0}^p w_j(t)x_j(t) \\ &= \mathbf{w}^T(t)\mathbf{x}(t) = \mathbf{x}^T(t)\mathbf{w}(t) \end{aligned} \quad (8)$$

em que foi feito $x_0 = -1$ e $w_0 = \theta$. O superscrito T indica a operação de transposição dos vetores. Assim, a ativação do neurônio no instante t é simplesmente o produto-escalar do vetor de entrada $\mathbf{x}(t)$ com o vetor de pesos $\mathbf{w}(t)$.

Note que a ativação $u(t) \in \mathbb{R}$ pode assumir infinitos valores, das mais variadas amplitudes. Contudo, para algumas aplicações, tal como classificação de padrões, a saída só deve assumir um número finito de valores possíveis. Dá-se o nome de *quantização escalar* ao processo de transformar a saída contínua $u(t)$ em uma saída discreta $y(t) \in \{-1, 1\}$.

Uma função quantizadora bastante utilizada em reconhecimento de padrões é construída com a **função sinal** (*sign function*), definida como:

$$y(t) = \text{sign}(u(t)) = \begin{cases} +1, & \text{Se } y(t) > 0 \\ 0, & \text{Se } y(t) = 0 \\ -1, & \text{Se } y(t) < 0 \end{cases} \quad (9)$$

Dica Importante! - A codificação das saídas desejadas para um dado problema de classificação deve ser compatível com a saída da função quantizadora. Note que as saídas desejadas em problemas de reconhecimento de padrões correspondem ao rótulo numérico da classe do vetor de entrada correspondente. Assim, para o caso da função sinal, as saídas desejadas podem assumir apenas os valores -1 ou $+1$.

A acurácia instantânea (ou seja, no instante t) do modelo ADALINE como aproximador do mapeamento $\mathbf{F}(\cdot)$ é medida com base no **Erro Quadrático** (EQ) no instante t , definido como

$$\varepsilon(t) = \frac{1}{2}e^2(t) = \frac{1}{2}(d(t) - u(t))^2, \quad (10)$$

em que $e(t) = d(t) - u(t)$ é o erro associado à apresentação do par entrada-saída atual $(\mathbf{x}(t), d(t))$. Note que o índice μ

Assim, define-se a seguir uma medida global do desempenho do modelo ADALINE, chamada de **Erro Quadrático Médio** (EQM), com base nos erros produzidos para todos os pares entrada-saída $\{\mathbf{x}(t), d(t)\}$:

$$J[\mathbf{W}] = \frac{1}{2N} \sum_{t=1}^N J(t) = \frac{1}{2N} \sum_{t=1}^N e^2(t) = \frac{1}{2N} \sum_{t=1}^N [d(t) - u(t)]^2 \quad (11)$$

em que $\mathbf{W}$ denota o conjunto de todos os parâmetros ajustáveis do modelo (pesos e limiares).

Os parâmetros do modelo ADALINE devem ser especificados a fim de que este produza sempre uma saída $y(t)$ bem próxima da saída esperada $d(t)$ para um vetor de entrada $\mathbf{x}(t)$ qualquer. Em outras palavras, o funcional $J(t)$ deve ter o menor valor possível para aquele conjunto de dados específico. Dá-se o nome de parâmetros ótimos aos valores de $\mathbf{w}$ e θ que alcançam este objetivo.

Uma equação recursiva, que implementa o conhecido método do gradiente descendente, é usada para atualizar os pesos do modelo sequencialmente, ou sejam após a apresentação de cada vetor de entrada:

$$w_j(t+1) = w_j(t) + \Delta w_j(t), \quad (12)$$

$$= w_j(t) - \alpha \frac{\partial J(t)}{\partial w_j(t)}, \quad (13)$$

$$(14)$$

em que a variável $0 < \alpha < 1$ é chamada de *taxa de aprendizagem* ou *passo de adaptação*. O termo de ajuste $\Delta w_j(t)$ é diretamente proporcional à derivada parcial $\frac{\partial J(t)}{\partial w_j(t)}$, que denota o gradiente instantâneo da função $J(t)$ em relação ao peso $w_j(t)$. A presença do sinal $(-)$ nessa equação indica que o problema de otimização subjacente é um problema de minimização.

Utilizando a regra da cadeia, a derivada parcial presente na Equação (12) pode ser fatorada da seguinte forma:

$$\frac{\partial J(t)}{\partial w_j(t)} = \frac{dJ(t)}{de(t)} \frac{de(t)}{du(t)} \frac{du(t)}{dw_j(t)} \quad (15)$$

em que os resultados das quatro derivadas para o modelo ADALINE são mostrados a seguir:

$$\frac{dJ(t)}{de(t)} = e(t) \quad (16)$$

$$\frac{de(t)}{du(t)} = -1 \quad (17)$$

$$\frac{du(t)}{dw_j(t)} = x_j(t) \quad (18)$$

Assim, temos que a regra recursiva de ajuste do peso sináptico associado à j -ésima entrada, $x_j(t)$, é dada por

$$\begin{aligned} w_j(t+1) &= w_j(t) + \Delta w_j(t) \\ &= w_j(t) + \alpha e(t) x_j(t) \end{aligned} \quad (19)$$

A regra de ajuste dos parâmetros do modelo ADALINE é chamada de regra LMS ou regra de Widrow-Hoff. A versão vetorial da regra LMS, para o caso de um neurônio, é dada por

$$\mathbf{w}(t+1) = \mathbf{w}(t) + \alpha e(t) \mathbf{x}(t). \quad (20)$$

Para o caso em que há q neurônios, a regra de ajuste do vetor de pesos do i -ésimo neurônio é dada por

$$\mathbf{w}_i(t+1) = \mathbf{w}_i(t) + \alpha e_i(t) \mathbf{x}(t), \quad (21)$$

em que $e_i(t) = d_i(t) - y_i(t)$ corresponde ao erro do i -ésimo neurônio. Considerando a regra de aprendizagem do perceptron apenas do ponto de vista do peso sináptico w_{ij} podemos escrever:

$$w_{ij}(t+1) = w_{ij}(t) + \alpha e_i(t) x_j(t), \quad i = 1, \dots, q \quad j = 0, 1, \dots, p \quad (22)$$

em que x_j corresponde à j -ésima entrada. Analisando a Eq. (22), é possível concluir que atualização do peso w_{ij} depende apenas de informação *local*, ou seja, de informação disponível apenas naquela sinapse do neurônio i , seja através da entrada por meio de $x_j(t)$, seja na saída por meio de $e_i(t)$.

Para finalizar, vamos considerar uma notação matricial para a regra LMS, já apresentada sob uma notação vetorial na Eq. (21) e sob uma notação escalar na Eq. (22). A notação matricial permite que uma rede com múltiplos modelos ADALINE, ou simplesmente rede MADALINE, seja implementada em poucas linhas quando usamos softwares do tipo Matlab/Octave/Scilab para simulação computacional.

Considere que os vetores de pesos $\mathbf{w}_i$ estão organizados como linhas de uma matriz $\mathbf{W}$, ou seja

$$\mathbf{W} = \begin{pmatrix} \mathbf{w}_1^T \\ \mathbf{w}_2^T \\ \vdots \\ \mathbf{w}_q^T \end{pmatrix}, \quad (23)$$

em que $\dim(\mathbf{W}) = q \times (p+1)$. Organizando os erros gerados pelos q neurônios de saída no instante t em um vetor de erros $\mathbf{e}(t) = [e_1(t) \ e_2(t) \ \dots \ e_q(t)]^T$, podemos escrever a regra LMS da seguinte maneira:

$$\mathbf{W}(t+1) = \mathbf{W}(t) + \alpha \mathbf{e}(t) \mathbf{x}^T(t), \quad (24)$$

em que esta expressão atualiza a matriz de pesos $\mathbf{W}$ de uma só vez. Cada termo da Eq. (24) deve ter dimensões compatíveis, de modo que para isso ser possível o termo de correção envolve

o produto externo do vetor de erros $\mathbf{e}(t)$ com o vetor de entrada $\mathbf{x}(t)$. É por isso que o vetor de entrada aparece transposto nessa equação.

A versão matricial da regra LMS não é muito comum de se ver em livros, porém é extremamente vantajosa para implementação em Octave, Matlab e Scilab, devido à maior velocidade que confere à execução do algoritmo. Usando a Eq. (24) a matriz de pesos $\mathbf{W}$ é atualizada de uma vez a cada apresentação de um vetor de entrada. Note que isto só é possível porque o funcionamento de cada neurônio é independente do funcionamento dos demais, dada a natureza local da regra de aprendizado LMS.

O processo de ajuste dos pesos, também chamado de *fase de aprendizado* ou *fase de treinamento* do modelo ADALINE equivale a um aprendizado que depende de um sinal de saída conhecido previamente, ou como se diz no jargão da área, depende de uma saída desejada $d(t)$ fornecida por um “supervisor” externo a fim de guiar o processo de ajuste dos parâmetros, conforme ilustrado na Figura 3. Por este motivo, este tipo de aprendizado é chamado também de *aprendizado supervisionado*.




Figura 3: Aprendizado supervisionado.

3 Treinamento, Convergência e Generalização

O algoritmo ADALINE pode ser utilizado tanto para aproximação de funções, quanto para classificação de padrões. Em ambos os casos, a avaliação deste modelo é comumente dividido em duas etapas descritas a seguir.

Fase de Treinamento - Nesta etapa, um determinado número $N_1 < N$ de pares entrada-saída $\{\mathbf{x}_\mu \mathbf{d}_\mu\}$ são escolhidos aleatoriamente para formar o *conjunto de dados de treinamento*. Não existe regra definida para a escolha de N_1 ; em geral, faz-se $N_1/N \approx 0,75$ ou $0,8$. Os N_1 pares são então apresentados, um por vez, para o modelo ADALINE, que tem seus pesos modificados segundo a Equação (19).

Toda vez que se apresenta todos os N_1 vetores de treinamento, diz-se que uma *época de treinamento* foi completada. Em geral, o conjunto de treinamento é apresentado mais de uma época ao modelo ADALINE, sendo que a ordem de apresentação dos pares entrada-saída deve ser mudada a cada época.

O treinamento deve ser interrompido quando o aprendizado convergir, ou seja, quando o EQM ($J(t)$), mostrado na Equação (11), alcançar um limite inferior J_{min} previamente estabelecido, ou seja, quando $J(t) < J_{min}$. O gráfico $J(t) \times K$, em que K define a época de treinamento, é chamado de *Curva de Aprendizagem* da rede neural. **Outro critério de parada para o treinamento envolve simplesmente a especificação de um número máximo ($K_{max} \in \mathbb{N}^+ \gg 1$) de épocas de treinamento. Normalmente, os dois critérios são usados simultaneamente.**

Fase de Teste - Para validar o modelo ADALINE treinado, ou seja, dizer que ele está pronto para ser utilizado, é importante testar a sua resposta para dados de entrada diferentes daqueles vistos durante o treinamento. Durante esta fase os pesos da rede não são ajustados.

Os pares entrada-saída de teste podem ser obtidos através de novas medições, o que nem sempre é possível de se realizar. A opção viável então consiste na utilização dos $N_2 = N - N_1$ pares entrada-saída restantes, chamados de *conjunto de teste*. A avaliação, em geral, é feita também com base no valor do EQM. O valor de $J(t)$ calculado com os pares entrada-saída de teste é chamado de *erro de generalização* do modelo ADALINE, pois testa a capacidade deste em “extrapolar” o conhecimento aprendido durante o treinamento para novas situações.

É importante ressaltar que, geralmente, o erro de generalização é maior do que o erro de treinamento, pois trata-se de um novo conjunto de dados.

Por outro lado, quando se utiliza o modelo ADALINE para classificar padrões, o seu desempenho é avaliado pela *taxa de acerto na classificação*, definida como:

$$P_{epoca} = \frac{\text{Número de vetores classificados corretamente}}{\text{Número de total de vetores}} \quad (25)$$

em que o número de vetores classificados corretamente é calculado com base na saída quantizada $y(t)$, que só assume dois valores, ou seja, $y(t) = +1$, se o vetor de entrada $\mathbf{x}(t)$ pertence a uma certa classe, e $y(t) = -1$ se o vetor $\mathbf{x}(t)$ pertence a uma outra classe.

4 Modelo MADALINE

O modelo ADALINE, na forma como foi descrito anteriormente, apresenta uma única saída. A generalização para várias saídas é muito simples, tal como foi feito para o Perceptron Simples. Um modelo ADALINE com múltiplas saídas passa a ser chamado de MADALINE (Multiple ADALINE).

Assim, para o caso de haver M saídas, as regras de ativação e de saída para um dado exemplo de treinamento $\{\mathbf{x}(t), \mathbf{d}(t)\}$ são escritas como:

$$u_i(t) = \sum_{j=0}^p w_{ij}(t)x_j(t) = \mathbf{w}_i(t)^T \mathbf{x}(t) \quad \text{e} \quad y_i(t) = u_i(t). \quad (26)$$

em que w_{ij} refere-se ao peso que conecta a j -ésima entrada ao i -ésimo neurônio.

A regra LMS aplicada aos pesos w_{ij} passa a ser escrita como

$$w_{ij}(t+1) = w_{ij}(t) + \alpha e_i(t)x_j(t), \quad (27)$$

em que $0 < \alpha \ll 1$ é a taxa (passo) de aprendizagem. Na forma vetorial¹, a Eq. (27) pode ser escrita da seguinte forma

$$\mathbf{w}_i(t+1) = \mathbf{w}_i(t) + \alpha e_i(t)\mathbf{x}(t). \quad (28)$$

¹A forma vetorial é particularmente útil na implementação de modelos de redes neurais através de softwares como Matlab, Octave ou Scilab.

A avaliação do aprendizado do modelo MADALINE continua sendo feita através do EQM, agora calculado levando-se em consideração os erros de todos os M neurônios de saída

$$J[\mathbf{W}] = \frac{1}{2N} \sum_{t=1}^N J(t) = \frac{1}{2N} \sum_{t=1}^N \sum_{i=1}^M e_i^2(t) = \frac{1}{2N} \sum_{t=1}^N \sum_{i=1}^M [d_i(t) - y_i(t)]^2, \quad (29)$$

em que d_i é a saída desejada para o neurônio i e y_i é a saída do neurônio i .

5 Exercícios Computacionais

Exercício 1 - Escolher um conjunto de dados no Repositório da Universidade da Califórnia em Irvine (<http://www.ics.uci.edu/~mllearn/MLSummary.html>) e utilizar os pares de vetores entrada-saída correspondentes para avaliar o modelo ADALINE (ou MADALINE) em um problema de classificação de padrões. Determinar a curva de aprendizagem (EQM em função da época de treinamento) e as taxas de acerto médio, mínimo e máximo na classificação.

Referências

- [1] B. Widrow and M. E. Hoff. Adaptive switching circuits. In *IRE WESCON Convention Record-Part 4*, pages 96–104, 1960.
- [2] B. Widrow and S. D. Stearns. *Adaptive Signal Processing*. Prentice-Hall, Upper Saddle River, NJ, 1985.
- [3] B. Widrow and R. Winter. Neural nets for adaptive filtering and adaptive pattern recognition. *IEEE Computer*, 21(3):25–39, 1988.
- [4] B. Widrow and M.A. Lehr. 30 years of adaptive neural networks: Perceptron, madaline and backpropagation. In *Proceedings of the IEEE*, volume 78, pages 1415–1442, 1990.