



Fundamentos de Aprendizado de Máquina

Introdução aos conceitos básicos, paradigmas e processos.



Nota: O Machine Learning (ML) nasceu na década de 60 como um campo da Inteligência Artificial focado em aprender padrões a partir de dados, e não de programação explícita.




O Limite Humano

Como lidar com bancos de dados onde há muito mais variáveis que observações?



A Complexidade Real


Como automatizar tarefas interpretativas complexas, como identificar dígitos manuscritos em imagens?



Nota: ML permite extrair valor de objetos complexos (como imagens e textos) que métodos estatísticos e manuais tradicionais não conseguem tratar bem.


Uma Nova Forma de Construir Soluções

Programação Tradicional



A cultura
algorítmica
inverte a lógica:
o foco é a
predição.

Machine Learning



Nota: No ML, o algoritmo “aprende” a regra a partir da experiência dos dados, não de instruções dedutivas.

Como as Máquinas Aprendem? A Grande Divisão


1. Supervisionado

Aprender com exemplos rotulados.




2. Não Supervisionado

Encontrar estrutura oculta sem rótulos.



3. Por Reforço

Aprendizado via tentativa, erro e recompensa.




Nota: O aprendizado supervisionado é o mais comum na indústria, pois sabemos a resposta correta para o conjunto de treino.

Supervisionado: Prevendo Valores Numéricos (Regressão)

Objetivo: Estimar uma variável quantitativa contínua (Y).

Mecânica: Buscar a relação matemática entre um vetor de características (x) e uma resposta real (Y).

Exemplo: Predizer a expectativa de vida de um país baseada no seu PIB.




Nota: A regressão não tenta classificar, mas sim encontrar a magnitude de um valor contínuo.

Supervisionado: Categorizando Informações (Classificação)

Objetivo: Estimar uma variável qualitativa/categórica (Y).

Mecânica: Minimizar a probabilidade de erro ao separar classes (o 'Classificador de Bayes').

Exemplo: Analisar um e-mail para definir se é SPAM ou NÃO-SPAM; ou identificar dígitos manuscritos.




Nota: O objetivo aqui é encontrar o Classificador de Bayes, a fronteira matemática que comete o menor número de erros.

Não Supervisionado: Agrupando por Similaridade (Clustering)

- Objetivo: Criar partições nos dados sem conhecer os grupos de antemão.
- Mecânica: Maximizar a similaridade interna do grupo e a diferença em relação aos outros.
- Exemplo: Segmentação comportamental de clientes de um e-commerce.

Nota: Os elementos no mesmo grupo devem ser o mais parecidos possível entre si, e o mais diferentes possível dos outros grupos.



A Linguagem do Machine Learning

[Features / Atributos] Variáveis explicativas, x .					[Target / Rótulo] A variável resposta, Y .	
[Dataset] Conjunto total de exemplos.	x_1	x_2	x_3	...	...	y
	x_1	x_2	x_3	...	...	y
	x_1	x_2	x_3	...	...	y
	x_1	x_2	x_3	...	...	y
	1.7	x_2	x_3	...	...	y
	0.8	x_2	x_3	...	...	y
	3.2	x_2	x_3	...	...	y
	0.9	x_2	x_3	...	...	y
	...	...	...	...	...	y
[Observação] Uma linha do dataset: X_i, Y_i .						


Nota: É fundamental padronizar e memorizar estes termos, pois eles formarão o vocabulário base de todo o restante do curso.

O Processo de Treinamento e a Função de Perda

O que é 'Ajustar' um modelo?

O algoritmo busca exaustivamente os parâmetros que tornem a predição ($r(x)$) o mais próxima possível da realidade (Y).

Nota: Treinar um modelo significa, puramente em termos matemáticos, estimar a função de regressão $r(x)$ minimizando o erro.




Medida de Erro (Loss) =
Diferença Vertical entre Predição ($r(x)$) e Realidade (Y)

Objetivo do Treinamento:
Minimizar a Soma/Média dessas Linhas de Erro


A Regra de Ouro: Treino vs. Teste

Nunca use os mesmos dados para treinar e avaliar o modelo!



[Treino - 70%]

Usado para o algoritmo aprender e ajustar os padrões.



[Teste - 30%]

Escondido do modelo. Usado apenas no final para estimar o erro real em dados novos.

Nota: Avaliar o modelo nos dados de treino é 'otimista demais' e esconde falhas catastróficas de generalização.

Generalização: O Objetivo Final do Algoritmo


O Conceito

A verdadeira inteligência de um modelo é sua capacidade de funcionar bem em dados inéditos que ele nunca viu. Ele não decora os dados; ele entende o padrão subjacente.

A Garantia Matemática


Lei dos Grandes Números: Se o conjunto de teste for grande o suficiente, o erro medido será próximo ao risco real de uso no mundo.

Nota: A analogia perfeita: um aluno que estudou (treino) vs. a aplicação de uma prova inédita (teste).




O Equilíbrio Crítico: Simplicidade vs. Complexidade

Underfitting (Sub-ajuste)




Modelo simples demais. Não capta o padrão.

O Ideal (Generalização)



Equilíbrio. Capta o padrão real.

Overfitting (Super-ajuste)



Modelo complexo demais. "Decorou" o ruído.

Nota: O overfitting ocorre quando o modelo se ajusta de forma tão extrema à amostra específica de treino que perde totalmente seu poder de generalização.

O Ecossistema de Dados

Inteligência Artificial (IA)


O campo amplo de máquinas realizando tarefas inteligentes (desde os anos 60).

Machine Learning (ML)

A ferramenta que foca em aprender padrões, na intersecção entre IA e Estatística.

Estatística

Fornece a base matemática, teórica e probabilística.



Ciência de Dados


A aplicação prática que utiliza ML e Estatística para resolver problemas de negócios.

Nota: Hoje, ML e Estatística são áreas indissociáveis e mutuamente benéficas. Uma não existe sem a outra na prática moderna.

Síntese Prática: Predição de Saúde Global




[Aprendizado Supervisionado: Regressão]



Nota: Este slide consolida a aula. Mostre como o polinômio de grau 4 generaliza perfeitamente a relação, enquanto o de grau 50 tenta conectar todos os países e gera um overfitting catastrófico.

O Caminho à Frente: Próximos Passos



Nota: Finalize motivando a turma. A transição da teoria de hoje para a prática das próximas semanas é onde a verdadeira consolidação do conhecimento acontece.

Resumo

- Os problemas da área de Machine Learning podem ser divididos em: **aprendizagem supervisionada**, **não supervisionada** e **por reforço**.
- Aprendizagem supervisionada pode ser formulada como problema de **regressão** ou de **classificação**
- **conjunto de treino** (usado para fazer o modelo aprender e ajustar padrões), **conjunto de teste** (usado apenas no final para estimar o erro real do modelo)
- **Underfitting** (modelo simples demais), **modelo ideal** (capta o padrão real), e **overfitting** (aprendeu demais; captou o ruído)